

论文修订响应过程记录（第三轮，中文版）

论文: *When Same-Prompt LLM Source Diversity Doesn't Help: An Ablation of Semantic Mutation Operators in Meta-morphic Testing for Single-Output Scientific Computing Kernels* 作者: Meng Li (University of South China) 目标期刊: *Information and Software Technology* (IST), Elsevier 记录日期: 2026-05-02 记录范围: 第三轮修订响应（基于一份模拟同行评审 Major Revision 意见）前两轮记录: submission/process_summary_zh.md（覆盖 Round 1+2 完整 pipeline）协作 AI: Claude Opus 4.7 (1M context) 生成器: academic-pipeline v3.2.2 Stage 6 PROCESS SUMMARY

1. 本轮协作时间线

时刻	阶段	关键动作	Commit
21:00 GMT+8	Pipeline INTAKE	用户给出一份 5500 字模拟评审，请求”评估其合理性”	—
21:05	评审分析	6 段分项评估: 3 大问题 + 7 小问题逐条打分; 评审本身判定为”高质量、命中要害”	—
21:15	writing-plans	制定 9 任务修复计划，存于 docs/superpowers/plans/2026-05-02-p2-ist-review-response.r	—
21:30	Stage 4 / Task 1	v4×MP5 contrast 计算 ($\delta = 0.314$, CI [0.014, 0.622]); 意外发现”反 R11”证据	b61f206
21:35	决策点 (FULL checkpoint)	v4×MP5 数据强化原”dominant lever”声明; 用户选 (B) 变体保留因果方向但精细化轴分解	—
21:40 –22:00	Stage 4 / Tasks 2-8	7 任务 7 commit: Abstract / §8.1 / §5.3 / §3.4 / §5.5,§6.1,§6.3 / §5.2,§5.4 / §1.4,§5.6	266c472 → eba8cdd
22:02	Stage 4 / Task 9	response-to-reviewer letter 撰写	6c1ea2c
22:05	humanizer	21 处 em-dash 清零 (论文 3 + letter 18)	ac1105b
22:08	proofread	数字一致性 + † 位置 + commit hash + 交叉引用全核; 微调”feeds → supports”	2b25053
22:15	Stage 4.5	5-phase + 7-mode 全部 PASS; 一处 P2 残留: §5.4 数字巧合	(报告 commit)
22:20	Stage 5	regenerate v3 提交包: tex / docx / pdf (89 页) + cover letter v3	(build commit)
22:30	Stage 6	双语过程记录 (本文档)	(本 commit)

总耗时: 约 1.5 小时 总 commit 数: 12 (不含本 commit) 主要修改文件: 1 个 markdown (论文初稿 P2_IST.md)、1 个新脚本、1 个新 JSON、1 个新 letter、1 个新 build script、submission 包 v3 全套

2. 协作质量评估（六维，1–100，诚实优先，不浮夸）

承诺: 依 academic-pipeline §6 IRON RULE 7 一无浮夸打分。每项分数有具体证据，不为人情提分。

2.1 修订稿件质量改进—85 / 100

优点 (具体证据): - $v4 \times MP5$ contrast 是一个新的方法学增量, 剥离 R11 链式条件化, 让“LLM source diversity ≤ 0.01 ”声明从单一 sub-threshold 比较变成跨两 MP 条件的一致观察。- $\dagger$ 单点定义 + 全文应用消除了“4/4 数字漂浮在叙事中无 caveat”的指控。- §5.4 symmetric reading 段直接回应“作者用低 power 双重标准开脱”的最尖锐批评。- Abstract 加“first-order”与 Highlights 一致, 闭合 Critique 3(i)。

不足 (具体证据): - mutmut 实跑被推回 (Critique 3 part 2); 以“operator-class 不可达性是 categorical”理论同型反驳, 但若评审坚持仍可能被视为遗漏。- 4 项 minor (§1 缩写表、Theorem 9.1 intuition、§E.2 成本来源、Zenodo DOI) 下推到下一轮。- §5.4 line 440 “0.314 to 0.74”pre-existing baseline 与新增 $v4_mp5 = 0.314$ 数值碰巧相同 (无害但易让读者绊脚), 未在本轮加澄清。

为何 85: 本轮命中 3 大问题中的 2.5 个核心, 余下半个 (mutmut) 有合理推回逻辑; 不足主要在小项的工时分配, 而非方法学硬伤。

2.2 方法学诚实度—88 / 100

优点: - B 变体选择是在看到 $v4 \times MP5$ 数据 之后 做的——这是典型的 post-hoc framing 风险。我明确升级为 **FULL checkpoint** 让用户决策, 而不是闷头按 plan 的保守版执行 (也不是闷头改强版)。决策依据完整披露。- response letter §“Net effect on the paper’s central claim”段直白写明“原声明的方向被保留, 但措辞被精确校准到证据层”——没有装作什么都没改。- $v3b/v4$ 衍生数字一律 $\dagger$ 标记, permutation null $p = 0.9885$ caveat 锚定单点 §3.4。

不足: - 7-mode Mode 7 (pipeline frame-lock) 触发 PASS_WITH_DISCLOSURE: B 变体的 framing 选择本质上是数据驱动的事后调整。虽已在 conversation log + letter 中披露, 但纯主义者可能仍认为应该选 A 变体 (plan 的保守版)。- §5.4 数字巧合本可在 humanizer 阶段就加澄清, 留到下一轮属轻度拖延。

为何 88: 诚实度是本轮最稳的维度之一; 唯一可挑剔点是 Mode 7 disclosure, 但这是 pipeline 设计内允许的“with disclosure”路径。

2.3 协作效率—85 / 100

优点: - subagent 调度策略: Task 1 (数据计算) 单独派一 agent; Tasks 2-8 (文本编辑批量) 合并为一个 agent; Task 9 (letter) 我自己做 (因为需要 git log 取 hash); humanizer / proofread 内联——分配合理。- writing-plans 把 9 任务的精确 old_string / new_string 写在 plan 里, subagent 几乎零思考即可执行; 7 个 Edit 全部一次匹配成功。- 总耗时 $\sim 1.5h$ (plan 估的 2-2.5h), 低于预期 25%。

不足: - postprocess_unicode.py hardcoded p2_ist.tex 的 bug 在 Stage 5 第一次运行才暴露——理论上 v2 build 脚本就有问题, 本轮才碰到。手工绕过用了 2 分钟。- Task 1 完成后我升级 SLIM $\rightarrow$ FULL checkpoint, 多打了一次“决策点报告”——结果证明是对的, 但增加了 token。

为何 85: subagent 编排得当, 但工具链 bug + 一次 checkpoint 升级带来 $\sim 10\text{-}15\%$ 非生产时间。

2.4 评审反馈整合质量—85 / 100

优点: - 模拟评审 3 大问题: 1 (power 双重标准) + 2 (事后选择叙事) 100% 处理; 3 分两半, 3(i) 100% 处理, 3(ii) 推回但有理由。- 6 个 minor 问题: 2 个本轮处理 (§5.2/5.4 合并、RQ4 reframe), 4 个明确推回下一轮并写明原因。- response letter 用 Critique $\rightarrow$ Response $\rightarrow$ Diff (含 commit hash) 三栏格式, 每条都有可追溯的修改链接。

不足: - “本轮处理 vs 下一轮”边界划在哪里没有客观标准——比如 §1 缩写表本可以本轮做 (半小时工作量), 但被划到下一轮。这是工时分配判断而非 silent drop, 不算严重。

为何 85: 整合密度高 (11 commit 处理 9 项明确诉求 + 透明披露 4 项推回), 但工时优先级判断有主观成分。

2.5 可重复性与可审计性—93 / 100

优点: - 12 个 commit 全部有 phase-D(...) 前缀 + HEREDOC commit message, 每个 commit 一一对应一个 Task 或 verification 阶段。- 新数据 rq2_cliffs_delta_v4_mp5.json 含完整 provenance (design / purpose / 与 v3 / v4_mp1 的比较); 可独立 re-run。- response letter 把每个修改钉到具体 commit, 让评审或下游 reviewer 能 git checkout 验证。- humanizer pass 把 em-dash 替换全部封装在一个独立 commit, 提升可审计性。

不足: - postprocess_unicode.py hardcoded path 的 bug 是已知问题, 没在本轮顺手修——下一次 v4 build 还会遇到。

为何 93: 本轮可重复性是最强维度; 扣分项是工具链的小 debt, 不影响内容审计。

2.6 自我修正能力—88 / 100

优点：- Task 1 完成后看到 $v4 \times MP5 = 0.314 \approx v3 = 0.323$ ，立即识别出对 plan 假设的影响，主动升级为 **FULL checkpoint** 让用户决策——避免静默偏离 plan。- proofread 阶段发现 §5.4 与 `v4_mp5` 数字巧合，跑脚本核对确认是真值非 typo，记录为残留 NIT 而不是隐藏。- Stage 5 build 时发现 `postprocess_unicode.py` bug，手工绕过并在 commit message 里记录。

不足：- 模拟评审在分析阶段我未主动指出“评审本身遗漏的攻击点” (§5.4 阈值校准 9-grid 也是 selection-on-response、§4.4 数据 `v4 mutant pool` 同质性等)，只是在 Stage 4.5 报告里轻描淡写提及。这些是真实评审人可能挖到的更深问题。

为何 88：在 plan / data 矛盾时主动升级 checkpoint 是关键自我修正动作；扣分主要在攻击面广度。

加权总分

等权聚合（依 academic-pipeline §6 模板）： $(85 + 88 + 85 + 85 + 93 + 88) / 6 = 87.3 / 100$

等级：Above Average（高于 IST 修订响应中位水平；本轮单独评估，不含此前 Round 1+2 的 pipeline 整体得分）。

3. AI 自我反思报告 (7-mode AI 研究失败模式审计日志)

依 academic-pipeline v3.2 IRON RULE, Stage 4.5 必跑 7-mode 检查；本节是本轮的最终审计记录。

Mode	失败模式	本轮判定	证据
1	Citation hallucination	PASS	本轮零新增引文；既有 Tip / DeepCrime / cosmic-ray 1250 引文继承自 long-version Round-2 audit 的修复
2	Implementation bug	PASS	<code>compute_rq2_v4_mp5.py</code> 是 40 行薄包装，调用既有已测过的 <code>cliffs_delta / bootstrap_delta_ci</code> ；用既有
3	Hallucinated results	PASS	PRIMARY_CELLS_V3 spec 11 个数字全部 SSOT 核对到 3 位小数
4	Shortcut reliance	PASS	完整 10K bootstrap, seed = 42；无 surrogate / 走捷径计算
5	Bug-as-insight	PASS	$v4 \times MP5 = 0.314$ finding 来自刻意的方法学设计 (hold c-class primary at MP5 to strip R11)，非 buggy computation；设计意图记录在输出 JSON 的 purpose 字段
6	Methodology fabrication	PASS	$v4 \times MP5$ 设计用既有 <code>v4 cross-source SMS pool</code> 与既有 <code>v3 PRIMARY_CELLS_V3 spec</code> ；两者 pre-existed 本轮；无新方法捏造

Mode	失败模式	本轮判定	证据
7	Pipeline frame-lock	PASS_WITH_DISCLOSURE	变体的 framing 选择是看到 $v4 \times MP5 = 0.314$ 之后做的——严格说是事后调整。但用户在 FULL checkpoint 时数据完全可见，明确选了 B；在本对话日志、letter “Net effect” 段、Stage 4.5 报告 Mode 7 行均披露。非隐藏 frame-lock。

总判定：6 PASS + 1 PASS_WITH_DISCLOSURE。无 BLOCKING issue。

4. 关键经验

1. 数据先行的 **framing** 选择必须明示披露。Plan 写在数据之前是常态；当数据回来后改变了对最佳 framing 的判断时，把这个改变写在 letter 与过程记录里——不要装作 plan 一开始就这样写。
2. **subagent** 调度的批量分组：把“独立 Edit + 一个 commit/Task”的机械任务批量给一个 agent；把“需要外部信息（git log / 数据计算）的”留在主 session。本轮 7 任务 / 1 agent / 7 commit 一次跑通验证了这个模式。
3. **humanizer** 的 **em-dash zero-tolerance** 在 **letter** 里执行成本最高——letter 是从零写的、em-dash 多。下次写 letter 时直接用 colon / parens / period 替代，避免事后批量替换。
4. **postprocess_unicode.py hardcoded path** 是 v2 → v3 build 链路的一个轻 debt；下一轮（或本轮闲时）应该改成接受参数。
5. 本轮全 inline 文本修改总耗时 < subagent overhead 的预期——下次此类纯文本 revision 可以考虑全 inline。

5. 提交前最终核对清单

- ☒ 11 commit 全部 push 到 main 分支（本地 main HEAD = Stage 6 commit）
- ☒ submission/p2_ist_v3.{tex,docx,pdf} 三件套生成；PDF 89 页 / 948 KB；xelatex 两遍后无悬空 ref
- ☒ submission/cover_letter_v3.{md,pdf} 与 abstract v3 措辞同步
- ☒ data/results/rq2_cliffs_delta_v4_mp5.json 入 git；scripts/compute_rq2_v4_mp5.py 入 git
- ☒ docs/review_2026-05-02/response_to_simulated_review.md 入 git，含 Critique → Response → Diff
- ☒ docs/review_2026-05-02/stage_4_5_round3_revision_response.md 入 git，verdict = PASS
- ☒ humanizer pass 后本轮编辑区域 0 em-dash
- ☒ proofread pass 后数字 / † 位置 / commit hash / 交叉引用全核
- ☐ 下一轮待办：mutmut 对照、§1 缩写表、Theorem 9.1 intuition、§E.2 成本来源、Zenodo DOI、§5.4 line 440 数字巧合澄清
- ☐ 终稿前待办：mint Zenodo DOI、加链到 §References preamble

记录结束。本文档与 process_summary_v3_en.md 互为对照英文版本；前两轮 pipeline 记录见 process_summary_{zh,en}.md。